deckgen : dossier technique

Générateur de flashcards par IA, conteneurisé et orchestré

Auteur	Marc Awad
Formation	ESILV, MSc CSDS1, groupe A4-PAR-ALT
Module	Conteneurisation & Orchestration
Formateur	Maxime Cordeiro
Version	v1.0.0
Date	15 octobre 2026
Dépôt	github.com/marc-awad/deckgen

Projet individuel. Ce dossier remplace la soutenance orale : il présente l'architecture, les choix techniques, les démonstrations et les difficultés rencontrées, avec des liens vers la documentation détaillée du dépôt.

Sommaire

1. Synthèse 3
2. Grille de conformité à la consigne 4
3. Architecture et microservices 6
4. Conteneurisation et Docker Compose 7
5. Kubernetes 8
6. Démonstrations 9
7. CI/CD 10
8. Workflow Git et gestion de projet 11
9. Choix techniques et alternatives 12
10. Difficultés et solutions 13
11. Limites et améliorations 13
12. Usage de l'IA 14
13. Vidéo de démonstration 14
14. Pour aller plus loin 15

1. Synthèse

- **deckgen** transforme un cours collé en flashcards (question et réponse) importables dans Anki.
- La génération est faite par un modèle de langage **local** (Ollama, `gemma3:4b`) : gratuit, et le cours ne quitte pas la machine.
- Trois microservices conteneurisés (interface React/nginx, API Node.js, generator Python) et une base PostgreSQL.
- Lancement en une commande avec Docker Compose ; déploiement sur un cluster Kubernetes local.
- Pipeline GitOps : un tag Git publie les images sur GHCR, Argo CD applique la version au cluster.

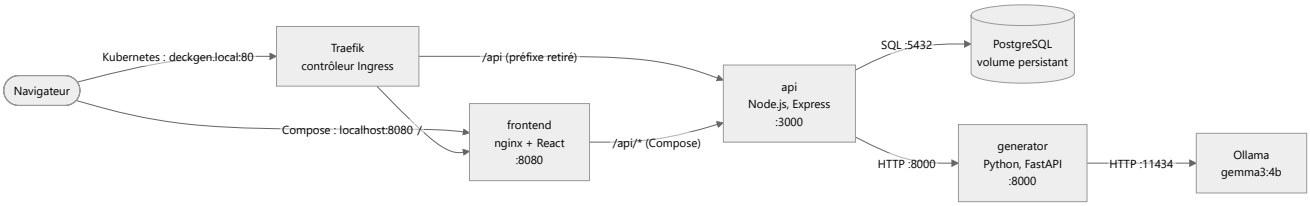


Figure 1 : Architecture de deckgen : services et flux, en mode Compose et en mode Kubernetes

3 microservices (React/nginx, Node.js, Python) et PostgreSQL	**123** tests automatisés (30 generator, 67 api, 26 frontend)	**9** status checks de CI exigés pour fusionner
-87 à -96 % de taille d'image grâce au multi-stage	**19** objets Kubernetes synchronisés par Argo CD	**v1.0.0** publiée le 15 octobre 2026, déployée en GitOps

2. Grille de conformité à la consigne

Exigence	Section	Fichier du dépôt	Preuve
Livrables			
Dépôt Git : `main` protégée, `develop`, branches `feature/`, historique clair	8	rulesets GitHub, historique	4 rulesets actifs, Conventional Commits, une PR par issue
Un Dockerfile multi-stage par microservice	4	`api/Dockerfile`, `frontend/Dockerfile`, `generator/Dockerfile`	Tailles mesurées avant et après
`.dockerignore` et `.gitignore`	4	`*/.dockerignore`, `.gitignore`	`.env` exclu des images et de Git, vérifié
`docker-compose.yml` qui lance tout en une commande	4	`docker-compose.yml`, `docker-compose.gpu.yml`	`docker compose up --build`, ordre de démarrage vérifié
Un Deployment et un Service par microservice	5	`deploy/*.yaml`	19 objets `Synced` dans Argo CD (figure 8)
ConfigMap	5	`deploy/api.yaml`, `generator.yaml`, `frontend.yaml`	Valeurs lues dans les pods (`printenv`)
Secret, aucun secret en clair dans Git ni dans l'image	5, 10	Secret créé par commande	Recherche du mot de passe : 0 fichier dans le dépôt et les images
PV et PVC pour la base	5, 6	`deploy/postgres-storage.yaml`	Données conservées après suppression du pod
CI : tests sur `develop`	7	`.github/workflows/ci.yml`	PR bloquée par la CI (figure 6)
CD sur tag de `main` : build, push vers un registre, déploiement Kubernetes	7	`.github/workflows/release.yml`	Releases v1.0.0-rc.1 et v1.0.0 (figures 7 à 9), attestation vérifiée
Critères d'évaluation			
Qualité du code et de l'architecture microservices	3	`api/`, `generator/`, `frontend/`	123 tests, lint et typecheck en CI
Dockerfiles optimisés, compose structuré	4	Dockerfiles, compose	-87 à -96 %, non-root, réseaux isolés
Manifestes corrects, concepts bien utilisés	5	`deploy/`	kubeconform strict en CI, dry-run serveur
CI/CD automatisé déclenché par les tags (bonus)	7	`release.yml`, `deploy/cluster/argocd-application.yaml`	Tag v1.0.0 → cluster en v1.0.0, sans intervention
Documentation claire (architecture, choix, défis)	ce dossier	`docs/`, README	Sections 3, 9 et 10
Objectifs pédagogiques			
Conteneurisation et microservices	3, 4	Dockerfiles	Images non-root, une responsabilité par service

Docker Compose	4	`docker-compose.yml`	Healthchecks, `depends_on` conditionnels
Déploiement et mise à l'échelle sur Kubernetes	5, 6	`deploy/api.yaml` (HPA)	HPA de 2 à 5 pods sous charge
Objets essentiels	5	`deploy/`	Namespace, Deployment, Service, ConfigMap, Secret, PV, PVC, HPA, Ingress
Mises à jour sans interruption	6	`deploy/frontend.yaml`	0 erreur sur 379 visites complètes (page et script) pendant un rolling update, avec le cookie d'affinité Traefik ; figure 3
Auto-réparation	6	probes, Argo CD	57 requêtes sur 57, liveness, self-heal (figure 4)
CI/CD	7	`.github/workflows/`	Exécutions réussies, captures
Règles d'usage de l'IA			
Transparence : outils et parties concernées	12	README	Section « Usage de l'IA »
Compréhension du code généré	12		Explications fichier par fichier, relues
Validation et tests	12	CI	123 tests, 9 checks, tests manuels
Personnalisation	9, 10		Décisions de l'auteur, défauts détectés
Sécurité : aucun secret partagé	12		Mots de passe aléatoires hors de Git ; deux expositions déclarées et corrigées

3. Architecture et microservices

Service	Rôle	Technologie	Image de base	Port
frontend	Interface web ; avec Compose, relaie `/api/` vers l'api	React 19, TypeScript, Vite, Tailwind CSS, nginx	`node:24.21.0-alpine3.24` (build), `nginxinc/nginx-unprivileged:1.30.5-alpine3.24`	8080
api	API REST : decks, cartes, génération, export Anki	Node.js 24, Express 5, TypeScript, Drizzle ORM, zod	`node:24.21.0-alpine3.24`	3000
generator	Transforme un cours en cartes en appelant Ollama	Python 3.13, FastAPI, httpx, pydantic	`python:3.13.16-slim-trixie`	8000
postgres	Stockage des decks et des cartes	PostgreSQL 18.6	`postgres:18.6-alpine3.24`	5432
ollama	Serveur du modèle de langage	Ollama 0.40.3, `gemma3:4b`	`ollama/ollama:0.40.3` (Compose) ; installé sur Windows (Kubernetes)	11434

Fonctionnalités : création d'un deck à partir d'un cours (50 à 20 000 caractères, 1 à 30 cartes au plus), génération bornée selon la longueur du cours, modification et suppression des cartes et des decks, export texte pour Anki (testé avec Anki), version affichée en pied de page.

Communication

- **HTTP partout** : le navigateur appelle `/api/...` ; l'api appelle le generator (`POST /generate` , JSON) ; le generator appelle Ollama. Seule l'api parle à PostgreSQL.
- **Résolution par nom** : DNS de Docker avec Compose, DNS du cluster sur Kubernetes (`generator` , ou `api.deckgen.svc.cluster.local`). Aucune adresse IP dans la configuration.
- **Une seule origine** : interface et api servies par la même adresse (nginx ou Traefik), donc pas de CORS, et la même image de frontend fonctionne partout.
- **Délais en cascade** : 120 s par appel à Ollama (deux tentatives au plus), 300 s pour l'api, un peu plus pour nginx et Traefik. Le service le plus proche du problème répond (504).

Principes microservices appliqués

- **Responsabilité unique** : le frontend affiche, l'api gère les données, le generator ne parle qu'au modèle.
- **Base possédée par un seul service** : seule l'api accède à PostgreSQL et applique les migrations (Drizzle).
- **Communication par API** : contrats JSON validés des deux côtés (zod, pydantic), erreurs normalisées (`{"detail": "..."}` , codes 422, 502, 503, 504).
- **Indépendance** : un Dockerfile, des tests et un nombre de pods par service.
- **Configuration externe** : variables d'environnement ; un service refuse de démarrer si une variable obligatoire manque.

4. Conteneurisation et Docker Compose

Dockerfile de l'api, à trois étapes (extrait) :

```
# Étape 1 : toutes les dépendances, puis compilation TypeScript vers dist/
FROM node:24.21.0-alpine3.24 AS build
COPY package.json package-lock.json ./      # dépendances avant le code : couche en cache
RUN npm ci
COPY tsconfig.json ./
COPY src ./src
RUN npm run build
# Étape 2 : dépendances de production seulement
FROM node:24.21.0-alpine3.24 AS prod-deps
COPY package.json package-lock.json ./
RUN npm ci --omit=dev --omit=optional
# Étape finale : ni TypeScript ni dépendances de développement ; npm retiré, tini en PID 1
FROM node:24.21.0-alpine3.24
RUN apk add --no-cache tini && rm -rf /usr/local/lib/node_modules/npm ...
COPY --from=prod-deps /app/node_modules ./node_modules
COPY --from=build /app/dist ./dist
USER 1000:1000                              # non-root, uid numérique vérifiable par Kubernetes
ENTRYPOINT ["/sbin/tini", "--"]
CMD ["node", "dist/index.js"]
```

Service	Naïve (disque / compressée)	Optimisée (disque / compressée)	Gain
generator	1,75 Go / 459 Mo	**221 Mo / 53 Mo**	-87 % / -88 %
api	2,2 Go / 570 Mo	**279 Mo / 65 Mo**	-87 % / -89 %
frontend	2,13 Go / 548 Mo	**90,5 Mo / 25,7 Mo**	-96 % / -95 %

Version naïve : une seule étape, image de base complète, `COPY . .`, toutes les dépendances.

Sécurité des images

- Non-root avec uid fixes (101 nginx, 1000 api, 10001 generator) ; tags fixés, jamais `latest`.
- `.dockerignore` (`.env`, tests, caches) ; aucun secret : recherche du vrai mot de passe dans les trois images, 0 résultat.
- tini (arrêt propre en moins d'une seconde), healthchecks sur `/health`, scan Trivy en CI.

Docker Compose : `docker compose up --build` lance tout, sans rien installer d'autre que Docker.

- **Services** : `postgres`, `ollama`, `ollama-pull` (télécharge le modèle une fois), `generator`, `api`, `frontend`. Les `depends_on` conditionnels imposent l'ordre (base healthy avant l'api, modèle téléchargé avant le generator).
- **Volumes** : `postgres-data` et `ollama-models` ; après `down` puis `up`, les decks sont là et l'application est prête en 15 s.
- **Réseaux isolés** : `front` (frontend, api) et `back` (api, generator, postgres, ollama). Depuis le frontend, la base et le modèle sont injoignables, vérifié.
- **Variables** : `.env` copié depuis `.env.example`, ignoré par Git ; `${VAR:?message}` arrête compose si une variable manque.
- **GPU** : surcharge `docker-compose.gpu.yml` ; environ 3 s par génération courte sur GPU, contre environ 25 s sur CPU.

5. Kubernetes

Cluster de Docker Desktop (kubeadm, un node, v1.36.1), namespace `deckgen`. Traefik, metrics-server et Argo CD sont installés une fois ; Ollama reste sur Windows, avec le GPU.

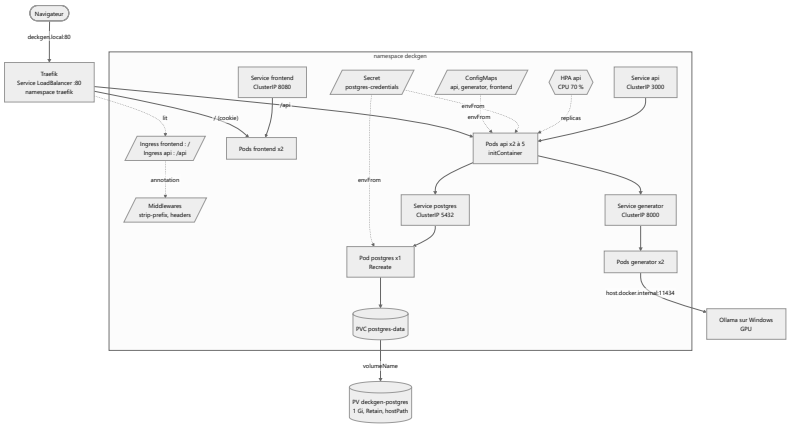


Figure 2 : Objets Kubernetes du namespace deckgen et leurs liens

Objet	Rôle dans deckgen
Namespace	`deckgen` regroupe toute l'application ; annoté pour qu'Argo CD ne le supprime jamais
Deployment	Un par service : frontend 2 pods, api 2 à 5, generator 2 (RollingUpdate, maxSurge 1, maxUnavailable 0) ; postgres 1 pod en `Recreate`
Service	ClusterIP pour chaque service ; seul Traefik est exposé (LoadBalancer, port 80)
ConfigMap	Un par service, injecté par `envFrom` : adresses, délais, modèle ; aucune valeur dans les Deployments
Secret	`postgres-credentials`, créé par `kubectl create` avec un mot de passe aléatoire ; jamais dans Git
PersistentVolume	`deckgen-postgres` : 1 Gi, `hostPath` `/var/lib/deckgen/postgres`, politique `Retain`
PersistentVolumeClaim	`postgres-data`, liée explicitement au PV (`volumeName`), montée par postgres
Probes	startup, liveness (redémarrage) et readiness (retrait du trafic) ; aucune liveness ne dépend d'un autre service
Requests / limits	D'après des mesures ; postgres en QoS Guaranteed (requests = limits)
HorizontalPodAutoscaler	api de 2 à 5 pods, cible 70 % de 100m CPU ; pas de champ `replicas` dans le Deployment
initContainer	`wait-for-postgres` : l'api attend que la base accepte les connexions
Ingress	Traefik : `/` vers le frontend, `/api` vers l'api (préfixe retiré, en-têtes de sécurité) ; cookie d'affinité pour le frontend
Kustomize	`kustomization.yaml` liste les 7 manifestes ; la release y ajoute les images GHCR (version et digest)

Détails : docs/kubernetes.md, deploy/README.md.

6. Démonstrations

Démonstration	Résultat mesuré
Scaling et HPA (4 flux de requêtes sur l'api)	2 pods → 4 à +31 s (539 % de CPU) → 5 à +95 s ; après l'arrêt de la charge, retour à 2 pods à +5 min 37 s (fenêtre de stabilisation)
Auto-réparation (pod api supprimé, requêtes toutes les 200 ms)	Pod recréé en 2 s ; **57 requêtes sur 57 en HTTP 200**
Readiness (PostgreSQL à 0 réplica)	Pods api retirés du Service en moins de 10 s, RESTARTS inchangé ; de nouveau Ready au retour de la base
Liveness (processus d'un generator figé)	3 échecs de liveness, conteneur redémarré en 63 s
Rolling update et rollback (frontend 0.1.0 → 0.2.0 → 0.1.0)	748 requêtes sur 748 en HTTP 200 ; mais 93 chargements de page sur 318 en échec sur le script avant la correction (affinité), puis 0 sur 379 avec le cookie Traefik
Persistance (pod postgres supprimé)	Base retrouvée (« Skipping initialization »), deck intact, api sans redémarrage
Self-heal d'Argo CD (frontend passé à 3 pods à la main)	Argo CD remet les 2 pods déclarés dans Git

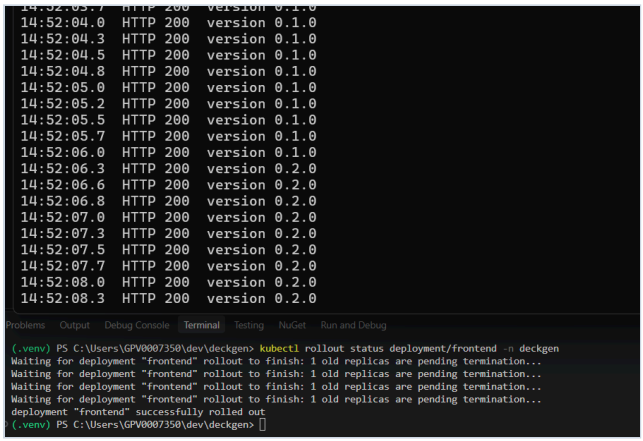


Figure 3 : Rolling update : la boucle de requêtes passe de 0.1.0 à 0.2.0, toujours en HTTP 200



Figure 4 : Self-heal : kubectl scale à 3 pods, Argo CD remet les 2 pods de Git

Détails : docs/rolling-update.md, docs/kubernetes.md.

7. CI/CD

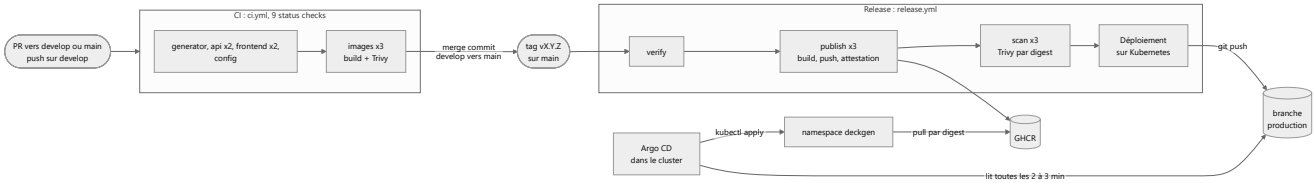


Figure 5 : CI sur chaque pull request, puis release sur tag et déploiement GitOps

CI (`ci.yml` , à chaque PR vers `develop` ou `main` et à chaque push sur `develop`)

- 9 jobs, tous status checks exigés : `generator` (ruff, pytest), `api` et `frontend` sur Node 20.19 et 24 (lint, typecheck, tests, build), `config` (compose, Kustomize, kubeconform), `images` x3.
- Trivy : rapport complet ; échec seulement sur une CRITICAL corrigeable. 0 CRITICAL dans les trois images.
- Actions épinglées par SHA de commit (l'action Trivy a été compromise par ses tags le 19 mars 2026, CVE-2026-33634) ; permissions minimales ; Dependabot chaque semaine.
- PR #42 : un test volontairement faux (1 + 1 = 3) dans le frontend bloque la fusion (figure 6).

Release (`release.yml` , sur un tag `vX.Y.Z` de `main`)

- `verify` (SemVer, commit sur `main`) → `publish` x3 (GHCR, tags `1.0.0` , `1.0` , `sha-…` , provenance, SBOM, attestation signée) → `scan` x3 (Trivy par digest) → Déploiement sur Kubernetes.
- Le déploiement écrit dans la branche `production` les images avec version **et** digest ; Argo CD l'applique. Aucun secret de dépôt : le `GITHUB_TOKEN` éphémère suffit.
- v1.0.0-rc.1 (2 min 4 s) puis v1.0.0 (1 min 59 s), le 15 octobre 2026, sur le commit `a8aadcc` .
- Attestation vérifiée : `gh attestation verify` confirme que l'image `deckgen-api@sha256:462866e0…` a été construite par `release.yml` depuis le tag v1.0.0 ; c'est le digest qui tourne dans le cluster.

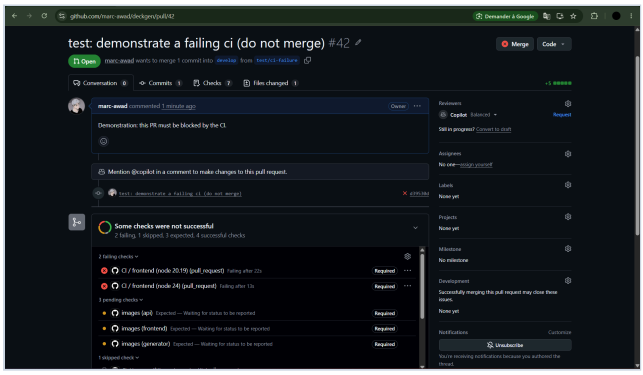


Figure 6 : PR #42 bloquée : 2 checks frontend en échec, fusion impossible

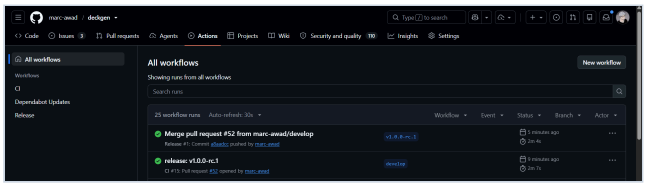


Figure 7 : Workflow Release réussi pour v1.0.0-rc.1, en 2 min 4 s

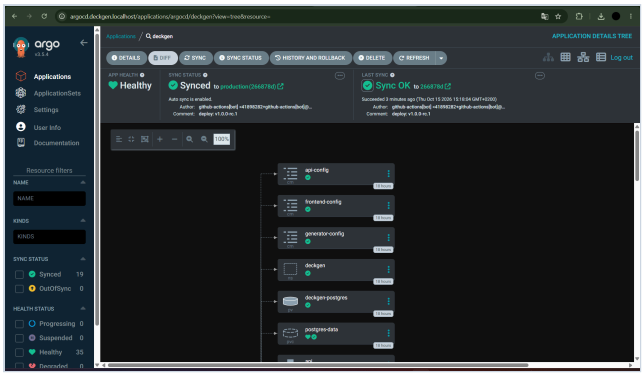


Figure 8 : Argo CD après la release v1.0.0-rc.1 : Synced et Healthy, 19 objets

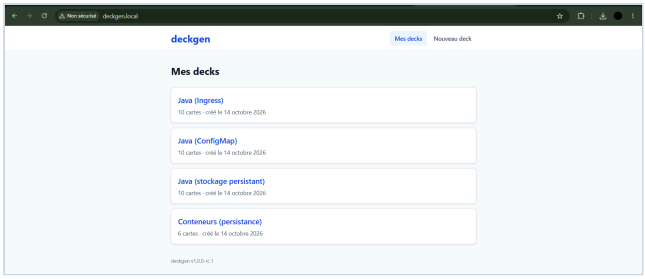


Figure 9 : Application servie par le cluster : pied de page « deckgen v1.0.0-rc.1 »

8. Workflow Git et gestion de projet

- **Branches** : `main` protégée (PR depuis `develop`, merge commit seul) ; `develop` par défaut (squash des branches `feature/…`, `fix/…`, `docs/…`, `chore/…`) ; `production` écrite par la release. Une branche et une PR par issue, sauf l'initialisation du dépôt (premier commit sur `main`).
- **Rulesets** : PR et 9 checks sur `develop` et `main` ; ni suppression ni force push sur `production` ; tags `v*` non modifiables.
- **Conventional Commits** : `feat(api): add decks and cards routes, generation and anki export (#26)`, `fix(generator): enforce card count bounds with JSON schema (#29)`, `ci: add github actions workflow with tests, image builds and trivy scan (#41)`.
- **Gestion de projet** : 22 issues (dont une de bug, #27) avec critères d'acceptation, 7 milestones (M0 Setup à M6 Documentation), GitHub Projects et labels.
- **Release** : tag annoté `vX.Y.Z` sur `main` ; retour arrière par `git revert` sur `production`.

9. Choix techniques et alternatives

Choix	Alternative écartée	Raison du choix
Node.js pour l'api	ASP.NET Core	TypeScript partagé avec le frontend, image plus légère ; l'auteur souhaitait ne pas utiliser ASP.NET
LLM local (Ollama)	API payante	Gratuit, les cours restent sur la machine
`gemma3:4b`	`gemma4:latest`	13 à 17 s contre 58 à 87 s pour 10 cartes (diagnostic de l'issue #27), 3,4 Go contre 9,6 Go, tient dans les 6 Go du GPU
Ollama sur l'hôte (Kubernetes)	Ollama dans le cluster	Accès direct au GPU, cluster local limité
PGlite pour les tests	Base de test dans un conteneur	Vraies migrations PostgreSQL en mémoire, aucun service externe en CI
Drizzle ORM	Prisma	Léger, proche du SQL, pas de moteur binaire dans l'image
Traefik	ingress-nginx	ingress-nginx retiré depuis mars 2026
GitOps avec Argo CD	Runner auto-hébergé, cluster cloud	Cluster non joignable depuis Internet, poste derrière un proxy, coût et GPU du cloud
Deployment `Recreate` pour PostgreSQL	StatefulSet	Même garantie pour une instance sur un node ; StatefulSet en production
PV `hostPath` statique	Provisionnement dynamique	Exigé par la consigne ; dynamique en production
Kustomize	Helm	Simple liste de fichiers ; la release y ajoute les images
Digest dans les manifestes	Tag seul	Un tag peut être republié, un digest non

10. Difficultés et solutions

Problème	Cause	Solution
Une seule carte générée pour un long cours (issue #27)	Le JSON schema ne fixait ni minimum ni maximum de cartes	Bornes `minItems` / `maxItems` ; ensuite 10, 6, 10, 10, 8, 10 cartes sur 6 essais
Scripts en 404 pendant un rolling update (93 visites sur 318)	Page servie par la nouvelle version, script demandé à l'ancienne	Affinité de session, puis cookie Traefik : 0 sur 379
nginx en 502 : « api could not be resolved »	Le `resolver` de nginx ignore les domaines de recherche du DNS	Nom complet `api.deckgen.svc.cluster.local`
Migrations en double au démarrage de plusieurs pods	Migrations lancées en parallèle (3 échecs sur 4)	Verrou consultatif PostgreSQL : 4 succès sur 4
Api démarrée avant PostgreSQL, puis redémarrée	Aucun ordre de démarrage entre pods	initContainer `wait-for-postgres` : RESTARTS 0
Générations longues coupées par Traefik	Hypothèse fausse sur `readTimeout` ; c'est `writeTimeout` qui coupe	`writeTimeout` à 330 s, vérifié par une génération de 88,8 s
Mot de passe recopié en clair dans l'annotation `last-applied-configuration`	`kubectl apply` sur un Secret	Secret créé par `kubectl create`
Pipeline incapable de joindre le cluster	Cluster local, poste derrière un proxy	GitOps : Argo CD va chercher la version, en sortie

11. Limites et améliorations

- Un seul node et un seul environnement : préproduction et cluster multi-node à prévoir.
- PV `hostPath` sans sauvegarde : StorageClass dynamique et `pg_dump`.
- Secrets non chiffrés dans etcd, pas de TLS : chiffrement au repos, cert-manager.
- Ollama hors du cluster : point unique de défaillance.
- 48 vulnérabilités HIGH dans l'image du generator, dont 4 corrigeables venant de pip : retrait de pip prévu.
- Ni tests de bout en bout, ni supervision (Prometheus, Grafana), ni authentification.
- Argo CD vérifie Git toutes les 2 à 3 minutes, sans webhook possible.

12. Usage de l'IA

Démarche. Le projet a été piloté de bout en bout par son auteur, avec l'IA comme outil de production. Cette section détaille ce qui a été fait par l'auteur et ce qui a été délégué à l'IA.

Travail de l'auteur

- **Décisions techniques** : sujet, stack (Node.js plutôt qu'ASP.NET, Python pour le service IA, LLM local plutôt qu'une API payante), Node 20 sur le poste et Node 24 dans les images, priorité à la persistance avant la configuration, Argo CD choisi parmi trois options (poste professionnel, proxy, budget, GPU).
- **Gestion de projet** : 21 issues et une issue de bug, avec critères d'acceptation ; GitHub Projects, milestones, labels ; une branche et une PR par issue ; rulesets ; Conventional Commits ; tri des PR de Dependabot.
- **Opérations** : environnement (Git, GitHub CLI, Docker Desktop, Kubernetes, Helm), cluster, fichier hosts, Argo CD et son mot de passe, rulesets, releases v1.0.0-rc.1 puis v1.0.0.
- **Validation** : test manuel de chaque fonctionnalité, import réel dans Anki, démonstrations avec captures, contrôle de chaque commit avant son envoi.
- **Détection de problèmes** : issue #27 diagnostiquée par des mesures avant correction, cartes répétées sur un texte court, modification hors périmètre écartée, erreurs d'environnement résolues (PATH, verrou Git, DNS, accès au cluster).

Travail délégué à l'IA

- **Claude (claude.ai)** : tuteur pour les notions du cours ; proposition du découpage en issues et du workflow Git ; rédaction des consignes données à Claude Code, à partir des besoins et des contraintes de l'auteur ; guidage des opérations et lecture des messages d'erreur.
- **Claude Code (extension VS Code)** : écriture du code, des tests, des Dockerfiles, des fichiers Compose, des manifestes, des workflows et de la documentation, avec une explication fichier par fichier.

Processus de validation. Aucune contribution de l'IA n'a été fusionnée sans les 123 tests automatisés, la CI (lint, typecheck, tests sur Node 20 et 24, build, Trivy), la lecture des explications fichier par fichier et un test manuel. Les erreurs de l'IA ont été corrigées en mesurant plutôt qu'en supposant (exemple : les délais de Traefik).

Sécurité. Deux mots de passe ont été affichés par erreur dans une conversation avec l'IA : le mot de passe administrateur initial d'Argo CD, changé immédiatement (et son Secret initial supprimé), et celui de PostgreSQL, remplacé ensuite (`ALTER USER` , puis mise à jour du Secret). Aucun autre secret n'a été partagé. Les mots de passe sont générés aléatoirement et stockés hors de Git ; les images, la CI et la release n'en contiennent aucun.

13. Vidéo de démonstration

Lien de la vidéo : [à compléter]

14. Pour aller plus loin

Document	Contenu
README.md	Présentation, lancement, choix techniques, workflow Git
docs/docker-images.md	Dockerfiles, tailles des images
docs/docker-compose.md	Services, réseaux, volumes, ordre de démarrage
docs/model-choice.md	Choix du modèle, diagnostic de l'issue #27
docs/kubernetes.md	Objets, probes, autoscaling, persistance, Ingress, mesures
docs/rolling-update.md	Rolling update et rollback, avec toutes les captures
docs/ci.md	Intégration continue, Trivy, épinglage, Dependabot
docs/cd.md	Release, GHCR, branche production, Argo CD
docs/release.md	Versionnement, étapes d'une release, retour arrière
deploy/README.md	Installation pas à pas sur Kubernetes